

深圳大学考试答题纸
(以论文、报告等形式考核专用)

2025-2026 学年度第一学期

课程编号	15046 60001	课序号	1	课程名称	自然语言处理	主讲教师	陈俊扬	评分
学号		姓名		专业年级				

教师评语：

本次大作业以“对抗性数据改写在欺诈对话检测中的应用”为主题，要求学生围绕近期自然语言处理文章（如 ACL、EMNLP）或人工智能会议（如 AAAI）中涉及对抗样本生成（adversarial example generation）、数据增强（data augmentation）、鲁棒性检测（robustness evaluation）的论文展开研究。学生需完成论文解读、方法复现，并在欺诈对话数据集上尝试改写数据，以降低现有大模型与传统分类器的判别准确率（实验一）。最后，需要在新改写的数据集上进行实验与分析。

作业要求学生能够：

- * 对当前主流 NLP 对抗攻击/数据改写方法的理解；
- * 掌握对话文本生成与改写相关的基本技术；
- * 能够将该类技术引入到欺诈检测场景中进行实证研究与分析。

一、背景介绍（20 分），要求该部分字数不少于两页：

- * 说明欺诈检测在智能客服、金融风控等场景的重要性；
- * 介绍大模型和传统分类器在欺诈对话识别上的现有研究与优势；
- * 引出模型准确率高但可能存在脆弱性的问题（参考实验一）；
- * 提出研究动机：如何通过改写欺诈对话数据（语义保持但表述不同）来降低模型准确率；
- * 说明使用的数据集：可以基于课堂提供的对话欺诈检测数据，或选取公开的客服/诈骗对话数据集。

二、相关工作的优缺点总结（10 分），要求该部分字数不少于一页：

- * 调研并总结已有对抗样本生成方法（如 TextFooler、BERT-Attack、Prompt-based 攻击等）；
- * 讨论它们在文本分类、对话系统中的应用及不足；
- * 说明近期研究的改进点（例如：更自然的改写、更强的迁移性）。

三、模型方法的解读（20 分），要求该部分字数不少于一页：

- * 选取目标论文的方法部分，逐步解读其公式、符号、损失函数含义；
- * 用文字和图示解释对话改写/对抗生成的整体流程；
- * 说明实验环境（硬件、软件依赖）；
- * 给出对比方法的选择理由（例如：与原始数据 vs 改写数据对比，大模型 vs 传统分类器对比）。

四、实验结果与分析（30 分），要求该部分字数不少于三页：

- * 展示原始数据集上的实验结果；
- * 展示改写后的数据集在分类器上的效果变化（准确率上升/下降情况）；

- * 分析实验现象：为什么某些改写能“骗过”模型；
- * 进行消融实验（如：只替换同义词 vs 改写整句，比较影响差异）。

五、将实现的代码和结果上传到 Github (务必上传代码,并复制链接到正文) (10 分)

六、参考文献(10 分)（要和正文内容联系，引用的地方加上序号，比如 xxx[1]）

题目： _____ 自拟题目

一、背景介绍包括

二、相关工作的优缺点总结

三、提出的模型方法的解读

四、实验结果展示

五、将实现的代码和结果上传到 Github

六、参考文献